





Laboratorio de Investigación en Ciencia de Datos & Inteligencia Artificial
Universidad Nacional de Luján

Aprendizaje por refuerzos

Práctica opcional

Objetivo:

El objetivo de este trabajo es afianzar los conceptos básicos del aprendizaje por refuerzo: el modelado de problemas de decisión secuencial como procesos de decisión de Markov, el cálculo de valores y políticas con iteración de valores y Q-learning, y el uso de redes neuronales para aproximar la función de valor en DQN.

Ejercicio 1: Conceptos

Un robot aspiradora limpia un departamento de tres habitaciones. Cada movimiento gasta batería, y puede volver a la base a cargar. A veces las ruedas patinan y no llega a la habitación elegida.

1. Proponga estados, acciones y recompensas para modelarlo como un proceso de decisión de Markov.
2. ¿Por qué no alcanza con un plan fijo y hace falta una política?
3. ¿Qué representa el factor de descuento γ? ¿Qué comportamiento espera con γ cercano a 0?
4. ¿Qué es el dilema entre exploración y explotación? ¿Cómo lo resuelve una política ε-greedy?

Ejercicio 2: Iteración de valores y Q-learning

Un MDP tiene dos estados, A y B, y un estado terminal T. Las transiciones son deterministas:

estado	acción	va a	recompensa
A	avanzar	B	0
A	quedarse	A	+1
B	salir	T	+10
B	volver	A	0

1. Con $\gamma = 0.9$ y valores iniciales $V(A) = V(B) = 0$, haga dos iteraciones de la iteración de valores. En cada una, indique la mejor acción en A.
2. Ahora el agente no conoce la tabla. Con todos los $Q(s, a)$ en cero, $\alpha = 0.5$ y $\gamma = 0.9$, vive el episodio A $\rightarrow$ avanzar $\rightarrow$ B $\rightarrow$ salir $\rightarrow$ T. Aplique la regla de Q-learning en cada paso.
3. ¿Qué necesita conocer la iteración de valores que Q-learning no necesita?

Ejercicio 3: Aproximación de funciones y DQN

En CartPole el estado son 4 números reales y hay 2 acciones. Se usa la red Input(4) $\rightarrow$ Dense(64, ReLU) $\rightarrow$ Dense(2).

1. ¿Por qué no se puede usar una tabla Q?
2. ¿Cuántos parámetros entrenables tiene la red? ¿Qué representa cada salida?
3. Si se entrena la red con cada transición a medida que llega, el agente no aprende. ¿Qué agrega DQN para resolverlo y qué resuelve cada parte?
4. Con $\gamma = 0.9$, la red objetivo da $(2.0,\ 3.0)$ para el estado siguiente de una transición con recompensa 1. Calcule el objetivo y. ¿Cuánto valdría si el estado siguiente fuera terminal?